

# CRITÉRIOS DE INFORMAÇÃO

O critério de informação é uma forma de encontrar o número ideal de parâmetros para um modelo.

A ideia vem de que a cada parâmetro adicionado, normalmente o erro diminui.

Essa diminuição se dá a custa do aumento de mais regressores

Para balancear a redução dos erros e o aumento do número de regressores, o Critério de Informação associa uma penalidade a esse aumento.

Se a penalidade for menor que a soma de resíduos, o regressor adicional deve ser adicionado ao modelo

Se a penalidade for maior que a diminuição da soma, o regressor adicional traz mais custos que benefícios e não deve ser adicionado

$$C = \ln \hat{\sigma}^2(T) + c_T \varphi(T)$$

$$\hat{\sigma}^2(T) = \frac{\sum_{t=1}^T \hat{\varepsilon}^2}{T} \text{ variância estimada dos resíduos}$$

$c_T$  número de parâmetros estimados

$\varphi(T)$  ordem do processo , que assim penaliza a falta de parcimônia,  
de poupança de parâmetros

O **melhor modelo** será o aquele que poupar mais parâmetros e conseguir a menor variância dos erros possíveis, o mais parcimonioso, ou seja com o **menor valor de Critério de Informação**

O primeiro termo mede a **adequação ao processo**

O segundo termo **penaliza a adição de parâmetros** para adequação ao processo.

O número de observações  $T$  é invariante sendo assim, é necessário comparar **processos com mesmo valor de  $T$** .

**BIC** (Bayesian Information Criterion) ou **SBC** (Schwarz Bayesian Criterion)

$$BIC = \ln \hat{\sigma}^2(T) + n \frac{\ln T}{T}$$

$n=p+q$ , se o modelo não tem constante e  $n=p+q+1$ , se há constante no modelo

AIC (Akaike Information Criterion)

$$AIC = \ln \hat{\sigma}^2(T) + n \frac{2}{T}$$

O melhor modelo será o aquele com menor AIC ou BIC.

Os modelos devem conter amostras iguais para serem comparados.

O critério AIC é mais forte que o BIC

```
"c:/Econometria/variacao.xls"
```

```
library(readxl)
```


```
variacao_PIB <- read.table("c:/Econometria/variacao.xls", header = T)
```

```
var_PIB <- ts(variacao_PIB$variacao_PIB, start = 1951, frequency = 1 )
```

```
view(var_PIB)
```


1	0.046684801
2	0.086833713
3	0.048361395
4	0.075815680
5	0.060637316
6	0.035029174
7	0.091244172
8	0.059991046
9	0.071589921
10	0.072027838
11	0.123370108
12	0.049186099
13	0.060550235

```
plot(var_PIB, main="Variação do PIB Brasileiro", col="Blue", ylab="%PIB", xlab="Ano")
```






`acf(var_PIB)`



`pacf(var_PIB)`



```
AR1 <- arima(var_PIB, order = c(1,0,0))
```

```
AR1
```

```
Call:
```

```
arima(x = var_PIB, order = c(1, 0, 0))
```

```
Coefficients:
```

	ar1	intercept
	0.4079	0.0472
s.e.	0.1155	0.0070

```
sigma^2 estimated as 0.001081:  log likelihood = 121.66,  aic = -237.33
```

```
AR1 <- arima(var_PIB, order = c(1,0,0))
```

```
AR1
```

```
Call:
```

```
arima(x = var_PIB, order = c(1, 0, 0))
```

```
Coefficients:
```

	ar1	intercept
	0.4079	0.0472
s.e.	0.1155	0.0070

```
sigma^2 estimated as 0.001081:  log likelihood = 121.66,  aic = -237.33
```

```
> AIC(AR1)
```

```
[1] -237.3294
```

```
MA1 <- arima(var_PIB, order = c(0,0,1))
```

```
MA1
```

```
call:
```

```
arima(x = var_PIB, order = c(0, 0, 1))
```

```
Coefficients:
```

	ma1	intercept
	0.2497	0.0473
s.e.	0.0950	0.0055

```
sigma^2 estimated as 0.001172: log likelihood = 119.26, aic = -232.52
```

```
> AIC(MA1)
```

```
[1] -232.5212
```

```
> BIC(MA1)
```

```
[1] -226.1886
```

```
ARMA11 <- arima(var_PIB, order = c(1,0,1))
```

```
ARMA11
```

```
call:
```

```
arima(x = var_PIB, order = c(1, 0, 1))
```

```
Coefficients:
```

	ar1	ma1	intercept
	0.8592	-0.5825	0.0476
s.e.	0.1341	0.2341	0.0111

```
sigma^2 estimated as 0.0009872: log likelihood = 124.34, aic = -240.68
```

```
> AIC(ARMA11)
```

```
[1] -240.6797
```

```
> BIC(ARMA11)
```

```
[1] -232.2362
```

	Modelo	AIC	BIC
1	AR1	-237.3294	-230.9968
2	AR2	-242.3609	-233.9174
3	MA1	-232.5212	-226.1886
4	MA2	-239.1580	-230.7145
5	MA3	-239.7428	-229.1884
6	MA4	-239.2085	-226.5432
7	MA5	-238.1168	-223.3407
8	MA6	-236.4707	-219.5837
9	MA7	-234.5466	-215.5487
10	MA8	-233.6382	-212.5295
11	MA9	-234.0163	-210.7967
12	ARMA11	-240.6797	-232.2362
13	ARMA12	-240.4454	-229.8910
14	ARMA13	-238.5126	-225.8474
15	ARMA14	-238.1479	-223.3718
16	ARMA15	-236.3529	-219.4660
17	ARMA16	-237.3793	-218.3814
18	ARMA17	-235.5106	-214.4018
19	ARMA18	-234.0767	-210.8571
20	ARMA19	-234.6009	-209.2704
21	ARMA21	-240.4378	-229.8835
22	ARMA22	-238.4566	-225.7913

	Modelo	AIC	BIC
28	ARMA28	-232.0770	-206.7465
3	MA1	-232.5212	-226.1886
29	ARMA29	-232.9323	-205.4910
10	MA8	-233.6382	-212.5295
11	MA9	-234.0163	-210.7967
19	ARMA18	-234.0767	-210.8571
9	MA7	-234.5466	-215.5487
20	ARMA19	-234.6009	-209.2704
27	ARMA27	-234.7986	-211.5790
18	ARMA17	-235.5106	-214.4018
26	ARMA26	-235.6621	-214.5534
24	ARMA24	-236.2659	-219.3789
16	ARMA15	-236.3529	-219.4660
8	MA6	-236.4707	-219.5837
25	ARMA25	-237.2775	-218.2796
1	AR1	-237.3294	-230.9968
17	ARMA16	-237.3793	-218.3814
23	ARMA23	-237.6172	-222.8411
7	MA5	-238.1168	-223.3407
15	ARMA14	-238.1479	-223.3718
22	ARMA22	-238.4566	-225.7913
14	ARMA13	-238.5126	-225.8474

	Modelo	AIC	BIC
29	ARMA29	-232.9323	-205.4910
28	ARMA28	-232.0770	-206.7465
20	ARMA19	-234.6009	-209.2704
11	MA9	-234.0163	-210.7967
19	ARMA18	-234.0767	-210.8571
27	ARMA27	-234.7986	-211.5790
10	MA8	-233.6382	-212.5295
18	ARMA17	-235.5106	-214.4018
26	ARMA26	-235.6621	-214.5534
9	MA7	-234.5466	-215.5487
25	ARMA25	-237.2775	-218.2796
17	ARMA16	-237.3793	-218.3814
24	ARMA24	-236.2659	-219.3789
16	ARMA15	-236.3529	-219.4660
8	MA6	-236.4707	-219.5837
23	ARMA23	-237.6172	-222.8411
7	MA5	-238.1168	-223.3407
15	ARMA14	-238.1479	-223.3718
22	ARMA22	-238.4566	-225.7913
14	ARMA13	-238.5126	-225.8474
3	MA1	-232.5212	-226.1886
6	MA4	-239.2085	-226.5432